

학위논문

**고위험 임상상황의 영양보충제 안전성 문헌에 대한
완전 AI 자율 근거지도 구축과
AI 참조표준 기반 선별 교차 확인**

*Fully AI-Autonomous Evidence Mapping of Dietary Supplement Safety in High-Risk Clinical
Contexts with AI-Reference Cross-Checking of Screening*

여형준

2026년 7월

제출 정보

이 문서는 여형준의 졸업논문 제출용 편집 기준본이다. 연구 내용과 검증된 수치는 본문에 반영되어 있으며, 아래 행정 정보는 소속 기관의 공식 양식에 맞춰 제출 전에 입력한다.

항목	내용
연구자	여형준
소속 대학	[입력]
학과·전공	[입력]
학번	[입력]
지도교수	[입력]
학위명	[입력]
최종 제출일	[입력]

연구 성격: 인공지능이 연구 질문과 검색식을 정의하고 선별·참조 판정을 직접 수행한 완전 자율 근거지도 연구.

사람의 독립 이중선별, 최종 RoB·GRADE, 임상 권고를 완료한 체계적 문헌고찰로 표시하지 않는다.

국문초록

본 연구는 고위험 임상상황에서의 영양보충제 안전성 문헌을 대상으로, 연구 질문(PICOS)과 PubMed 검색식을 사람이 아니라 인공지능이 정의하고, 문헌 선별과 참조 판정까지 인공지능 에이전트가 직접 수행하는 완전 자율 트랙(protocol v3.0)을 구축하고 그 산출물을 보고한다. 질문은 5개이며, 자료원은 PubMed 단일 자료원으로 한정하였다. 검색으로 확보한 코퍼스는 레코드-질문 단위 2,209건(고유 문헌 2,168건)이고, 이 가운데 초록이 있는 행은 1,968건, 제목만 있는 행은 241건이었다. 에이전트는 이 2,209행을 빠짐없이 직접 판정하여 커버리지 100%를 달성했고, 판정 분포는 retain 1,705건, deprioritize 461건, uncertain 43건이었다. 선별 품질을 가늠하기 위해 층화 무작위 표본 300건을 뽑아 P-I-C-O-S 축을 라운드 3회로 독립 채점하고 코드 규칙으로 참조 라벨을 도출했다. 층화 가중 결과 sensitivity_vs_ai_reference는 0.987, specificity_vs_ai_reference는 0.516, agreement_vs_ai_reference는 0.785였다. Rogan-Gladen 보정을 적용하면 코퍼스 수준 retain 규모는 겉보기 1,705건에서 1,264건(95% CI 1,165–1,359건)으로 낮아진다. 이 참조 판정은 사람이 만든 gold standard가 아니라 같은 에이전트가 블라인드 상태에서 다른 과업 정의로 수행한 내부 참조(ai_reference_standard)이므로, 위 값은 임상적 정확도가 아니라 교차 확인(ai_cross_checked) 결과로만 해석해야 한다. 본 연구의 모든 단계에서 사람의 연구 의사결정은 0건이다.

주요어: 영양보충제, 고위험 임상상황, 근거지도, 인공지능 자율 연구, AI 참조표준, Rogan-Gladen 보정, 출처 계보

Abstract

This study built a fully AI-autonomous evidence-mapping track in which the research questions and PubMed search strategies were defined by AI, and every record-question row of the resulting corpus was screened directly by the agent (coverage 100%, 2,209 rows). Screening quality was cross-checked against an AI reference standard scored blind on a stratified sample of 300 rows across 3 rounds. Weighted sensitivity_vs_ai_reference was 0.987 and specificity_vs_ai_reference was 0.516. After Rogan-Gladen correction the corpus-level retain volume falls from 1,705 to 1,264 rows. The reference standard is AI-generated, not a human gold standard, so these values are cross-check results rather than clinical accuracy. No human research decision was made at any stage.

목차

1. 서론

1.1 연구 배경

1.2 문제 제기

1.3 연구 목적과 질문

1.4 연구 범위

2. 이론적·방법론적 배경

2.1 완전 자율 트랙의 정의

2.2 AI 참조표준의 위치

2.3 유병률 보정의 필요

3. 연구 방법

3.1 질문과 검색식의 AI 정의

3.2 검색 실행과 코퍼스

3.3 에이전트 직접 선별

3.4 AI 참조표준의 생성과 채점

3.5 통계 처리

3.6 근거 번들과 공개 화면 연결

3.7 선행 트랙과의 비교 절차

4. 연구 결과

4.1 코퍼스 구성

4.2 선별 결과

4.3 참조 판정과의 대조

4.4 근거 번들

4.5 선행 트랙과의 비교

5. 고찰

5.1 주요 결과의 의미

5.2 방법론적 기여

5.3 실무적 함의

5.4 후속 연구

6. 연구의 한계

6.1 참조표준의 성격

6.2 독립성의 부분적 한계

6.3 사람의 연구 의사결정 부재

6.4 단일 자료원

6.5 원문 미접근

7. 결론

참고문헌

부록 A. 질문별 결과표

부록 B. 재현 경로와 파일 해시

1. 서론

1.1 연구 배경

영양보충제는 처방 없이 구할 수 있지만, 수술 전후·만성콩팥병·임신·간질환·항응고 치료처럼 위해가 커질 수 있는 상황에서는 성분의 평균적인 효과보다 노출량, 병용약, 기저질환, 관찰된 이상반응을 함께 확인해야 한다. 이런 확인에 쓰이는 근거는 무작위 대조시험부터 증례보고까지 여러 형태로 흩어져 있어, 무엇을 먼저 읽어야 하는지 정하는 일 자체가 하나의 과업이 된다.

문헌을 선별하는 작업은 전통적으로 두 명 이상의 사람이 독립적으로 수행하고 이견을 조정한다. 그러나 인력과 원문 접근을 확보하지 못한 연구 환경에서는 이 절차가 성립하지 않는다. 이때 선택지는 연구를 멈추거나, 자동화가 어디까지 할 수 있고 어디부터 할 수 없는지를 명시적으로 드러내는 설계를 만드는 것이다.

1.2 문제 제기

선행 트랙(protocol v2.1)은 사람이 정의한 질문과 검색식을 그대로 두고 자동 분류만 비교했다. 이 설계에서는 인공지능이 실제로 연구 질문을 세우고 검색 전략을 짜는 단계까지 담당했을 때 무엇이 달라지는지 관찰할 수 없다. 또한 자동 분류의 품질을 가늠할 기준이 없어, 분류 결과를 그대로 근거 규모로 읽으면 과대추정이 발생한다.

본 연구는 그 두 가지 공백을 겨냥한다. 첫째, 질문 정의와 검색식 작성부터 인공지능이 수행하는 독립 트랙을 만든다. 둘째, 같은 코퍼스에 대해 별도의 과업 정의로 참조 판정을 생성하고, 그 참조와의 대조 결과로 분류기의 걸보기 규모를 보정한다.

1.3 연구 목적과 질문

연구 목적은 네 가지다. 첫째, 인공지능이 정의한 고위험 임상상황 질문과 PubMed 검색식으로 선행 트랙과 분리된 코퍼스를 구축한다. 둘째, 그 코퍼스 전량을 에이전트가 직접 선별한다. 셋째, 층화 표본에 대해 축 단위 참조 판정을 만들고 층화 가중과 Rogan-Gladen 보정으로 코퍼스 수준 retain 규모를 추정한다. 넷째, 그 결과를 공개 화면의 근거로 연결하고 재현 경로를 해시로 고정한다.

질문은 표 1과 같이 다섯 개이며, 분석의 기본 단위는 개별 연구가 아니라 특정 문헌이 특정 질문에서 검색된 레코드-질문 단위다.

표 1. 연구 질문의 P-I-O 구성

질문 ID	대상(P)	노출(I)	결과(O)
-------	-------	-------	-------

HRS1_PERIOPERATIVE	수술 또는 침습적 시술을 받는 성인	수술 전 식이보충제 또는 허브 보충제 노출	출혈, 수혈, 마취 상호작용, 수술주위 합병증
HRS2_KIDNEY_DISEASE	만성콩팥병 또는 투석 환자	비처방 비타민, 무기질 또는 허브 보충제 노출	고칼륨혈증, 고칼슘혈증, 신독성, 심혈관 이상반응
HRS3_PREGNANCY	임신부와 태아 또는 신생아	임신 중 식이보충제 또는 허브 보충제 노출	산모 독성, 임신 합병증, 선천성 이상, 태아·신생아 이상반응
HRS4_LIVER_DISEASE	기존 간질환이 있는 성인 또는 소아 환자	식이보충제 또는 허브 보충제 노출	약인성 간손상, 간기능 악화, 간부전, 입원
HRS5_ANTICOAGULATION	비타민 K 길항제, 직접경구항응고제 또는 헤파린을 사용하는 환자	식이보충제 또는 허브 보충제 병용	주요·경미 출혈, 혈전색전증, 응고검사 변화, 약물 상호작용

1.4 연구 범위

본 논문은 임상 권고를 제시하지 않는다. 효과크기를 통합하거나 위험비를 계산하지 않고, 비뚤림 위험이나 근거 수준을 판정하지 않으며, PRISMA 흐름도의 최종 포함·제외 건수를 보고하지 않는다. 선별 라벨은 retain / deprioritize / uncertain이며 사람의 포함·제외 판정이 아니다.

2. 이론적·방법론적 배경

2.1 완전 자율 트랙의 정의

여기서 완전 자율이란 질문 정의, 검색식 작성, 검색 실행, 선별, 참조 판정, 번역, 집필까지 인공지능이 수행하고 사람의 연구 의사결정이 개입하지 않는 상태를 말한다. 자율성은 정확도의 주장이 아니라 절차의 기술이며, 그래서 이 논문은 자율 트랙의 산출물을 정확도가 아니라 재현 가능성과 내부 일관성으로 평가한다.

2.2 AI 참조표준의 위치

사람 gold standard가 없는 상황에서 분류기 성능을 평가하려면 비교 대상이 필요하다. 본 연구는 같은 에이전트가 블라인드 상태에서, 선별과 다른 과업 정의(축 단위 채점)로 만든 판정을 참조로 삼았다. 이를 ai_reference_standard로 부르고, 대조 결과는 진실 정확도가 아니라 ai_cross_checked 결과로 표기한다.

고위험 임상상황 영양보충제 안전성 근거지도 (protocol v3.0)

이 구분은 용어에서도 지킨다. 민감도·특이도·정확도를 단독으로 쓰지 않고 sensitivity_vs_ai_reference, specificity_vs_ai_reference, agreement_vs_ai_reference로 적는다.

2.3 유병률 보정의 필요

불완전한 검사로 관찰한 양성 비율은 참값이 아니다. 검사의 민감도와 특이도를 알면 Rogan-Gladen 보정으로 참 비율을 추정할 수 있다. 본 연구는 분류기를 검사로, 참조 판정을 기준으로 두고 이 보정을 적용해, 선별 결과를 그대로 근거 규모로 읽을 때 생기는 과대추정을 수치로 드러냈다.

3. 연구 방법

3.1 질문과 검색식의 AI 정의

연구 질문과 PubMed 검색식은 agent_local 방식으로 생성하였다. 정의 프롬프트는

research/searches_v3/ai_picos/prompt.txt에 두고 SHA-256

b8fd37a2463eab37b24e45174ae29c06f45450d92d9606cbdc50e82a6838e510로 고정했다. 정의 결과 파일의 SHA-256은

70e4749529fb2ad9db6bf7c7c45456b9761d7958a27ee728371ae68015f3912f다.

질문 선정의 근거는 다음과 같이 기록되어 있다. “환자 위해의 심각성이 커질 수 있는 임상상태를 먼저 나눈 뒤, 보충제 노출과 안전성 결과를 관찰할 수 있고 서로 임상적으로 구별되는 질문을 선택했다.” 정의 단계의 입력에서는 기존 질문 목록, 기존 검색식 초안, 기존 검색 결과 수치를 명시적으로 배제하여, 선행 트랙의 질문·검색식·결과 수치가 새 질문 정의에 흘러들어가지 않도록 했다.

3.2 검색 실행과 코퍼스

검색은 PUBMED를 대상으로 2026-07-26T16:36:28+00:00에 실행하였다. 질문별 hit 수와 확보 건수는 표 2와 같고, 합계 hit 수는 2,209건이다.

표준화한 코퍼스는 data/curated_v3/evidence_map.csv이며 레코드-질문 단위 2,209건, 고유 문헌 2,168건, SHA-256 3142e5259bd44acec1eb270aa66f9ff4d791e8c78013525a666f65a8bdc5b4d3다. 관찰 가능성은 초록 보유 1,968건, 제목만 241건으로 나뉜다.

표 2. 질문별 검색 실행 결과

질문 ID	대상(P)	hit	확보
-------	-------	-----	----

HRS1_PERIOPERATIVE	수술 또는 침습적 시술을 받는 성인	296	296
HRS2_KIDNEY_DISEASE	만성콩팥병 또는 투석 환자	138	138
HRS3_PREGNANCY	임신부와 태아 또는 신생아	515	515
HRS4_LIVER_DISEASE	기존 간질환이 있는 성인 또는 소아 환자	967	967
HRS5_ANTICOAGULATION	비타민 K 길항제, 직접경구항응고제 또는 헤파린을 사용하는 환자	293	293

3.3 에이전트 직접 선별

선별 프롬프트는 research/screening/v30_agent/prompts/screening_prompt.md에 동결하고 SHA-256 d7a41a5936d13ca9f5de926142ea2bdf4628285fab2edec581b391cbc58ffcc로 기록했다. 실행 방식은 agent_direct이며, 선별을 위한 별도 모델 호출은 0회, 외부 API 호출은 0회, 사람의 판정은 0건이다. 즉 에이전트가 배치를 읽고 모든 행을 직접 판정했다.

판정은 append-only 체크포인트(research/screening/v30_agent/checkpoints.jsonl, SHA-256 085ad6346ddbeaf3133b00f3503316e814d93c67c9ed23bb60c0aa399ce3497a)에 누적하고, 요청한 레코드-질문 쌍이 정확히 한 번씩 돌아왔는지 반복 검증하여 커버리지 100%에 도달한 뒤 확정했다. 최종 산출물은 data/curated_v3/llm_screening_classifications.csv(SHA-256 5305c69437114b9f157ff6fb10bf1dc0308b2fca1ddacb2d02fc3b6848450393)다.

초록이 없는 241행은 근거 형태를 title_only로 고정하고 confidence 상한을 low로 두었으며 사유 코드에 insufficient_abstract를 강제했다. 판정 실패나 파싱 오류라는 상태는 두지 않았고, 판단이 어려운 행은 uncertain으로 남겼다.

3.4 AI 참조표준의 생성과 채점

선별 결과를 층으로 삼아 층화 무작위 표본 300건을 뽑았다. 표본 시드는 20260727이며 층별 프레임 크기·표본 수·가중치는 표 5와 같다. 블라인드 파일에는 선별 라벨·confidence·사유 코드·배치 번호를 넣지 않았다.

참조 채점 프롬프트는 선별 프롬프트와 다른 과업을 정의한다. 주제 적합성을 통째로 묻지 않고 P·I·C·O·S 다섯 축을 각각 채점한 뒤, 종합 라벨은 사람이 아니라 코드의 명시적 규칙이 도출한다. 프롬프트는 research/validation/screening_ai_reference_v3/prompts/reference_picos_prompt.md에 동결했고 SHA-256은 20a5dcddc64f2b104fc6140a1422c5e16e035d65c58f61812d1067115e080b43다.

채점은 라운드마다 행 순서를 독립 무작위화하여 3회 수행했다(시드 20260727001, 20260727002, 20260727003). 세 라운드의 다수결로 참조 라벨을 정하고, 세 라벨이 모두 다르면 unresolved로 남기기로 했으나 실제 unresolved는 0건이었다. 분석에 사용한 단위는 300건이다.

참조 채점 역시 agent_direct 방식이며 모델 호출 0회, 외부 API 호출 0회, 사람의 판정 0건이다.

표 5. 층화 표본 설계

층	프레임 크기	표본 수	가중치
HRS1_PERIOPERATIV E::deprioritize	92	11	8.364
HRS1_PERIOPERATIV E::retain	194	24	8.083
HRS1_PERIOPERATIV E::uncertain	10	5	2.000
HRS2_KIDNEY_DISEA SE::deprioritize	11	5	2.200
HRS2_KIDNEY_DISEA SE::retain	126	15	8.400
HRS2_KIDNEY_DISEA SE::uncertain	1	1	1.000

HRS3_PREGNANCY:: deprioritize	85	11	7.727
HRS3_PREGNANCY:: retain	428	56	7.643
HRS3_PREGNANCY:: uncertain	2	2	1.000
HRS4_LIVER_DISEAS E::deprioritize	226	29	7.793
HRS4_LIVER_DISEAS E::retain	721	96	7.510
HRS4_LIVER_DISEAS E::uncertain	20	5	4.000
HRS5_ANTICOAGUL ATION::deprioritize	47	5	9.400
HRS5_ANTICOAGUL ATION::retain	236	30	7.867
HRS5_ANTICOAGUL ATION::uncertain	10	5	2.000

3.5 통계 처리

층별 추출률이 다르므로 단순 평균을 쓰지 않고 층화 가중치를 적용했다. 가중치는 층 프레임 크기를 층 표본 수로 나눈 값이다.

코퍼스 수준 retain 규모는 Rogan-Gladen 보정으로 추정했다. 신뢰구간은 층 안에서 복원 추출하는 층화 부트스트랩 10,000회의 백분위수 방식으로 계산했고 시드는 20260727777다. 통계 함수(층화 가중, Rogan-Gladen, 부트스트랩 CI, 백분위수, 라벨 도출 규칙, 층별 배분, kappa)에는 단위 시험을 붙였다.

3.6 근거 번들과 공개 화면 연결

선별을 통과한 문헌은 정규식 PICOS 추출 게이트와 결합하여 근거 번들로 만들었다. 정규식 게이트 통과 1,627행 가운데 선별 라벨이 retain이 아닌 274행이 제외되어 1,353행이 남았다. 질문당 상한 15건을 적용해 핵심 근거 75건을 선정했다.

핵심 근거의 한국어 핵심소견 번역은 외부 로컬 번역 모델을 호출하지 않고 에이전트가 직접 작성했다. 번역기는 원문의 숫자·단위·증감 방향이 보존되었는지 자동 검증하며, 검증에 실패하면 번들 생성이 중단된다.

3.7 선행 트랙과의 비교 절차

v2.1 트랙은 사람이 질문과 검색식을 정의한 비교 트랙으로 남기고 덮어쓰지 않았다. 두 트랙의 질문 포괄 관계, 검색식 용어 Jaccard, MeSH 사용, hit 수, PMID 교집합을 별도 도구로 산출했다.

4. 연구 결과

4.1 코퍼스 구성

코퍼스는 레코드-질문 단위 2,209건이며 자료원은 PUBMED 2,209건이다. 고유 문헌은 2,168건으로, 한 문헌이 둘 이상의 질문에서 검색된 경우가 있다. 이 값은 중복을 확정 제거한 연구 수가 아니다.

4.2 선별 결과

전체 2,209행의 판정 분포는 retain 1,705건, deprioritize 461건, uncertain 43건이었다. 질문별 분포는 표 3과 같다.

근거 형태별로 보면 초록이 있는 1,968행에서는 uncertain이 6건에 그쳤으나, 제목만 있는 241행에서는 37건이었다. 확신도 분포는 high 1,172건, medium 649건, low 388건이다.

표 3. 질문별 선별 판정 분포

질문 ID	retain	deprioritize	uncertain
HRS1_PERIOPERATIVE	194	92	10
HRS2_KIDNEY_DISEASE	126	11	1

HRS3_PREGNANCY	428	85	2
HRS4_LIVER_DISEASE	721	226	20
HRS5_ANTICOAGULATION	236	47	10

4.3 참조 판정과의 대조

다수결 참조 라벨의 분포와 라운드 간 일치는 표 6에 정리했다. 라운드 전체가 동일한 라벨을 준 비율은 98.0%였다.

총화 가중 결과 sensitivity_vs_ai_reference는 0.987, specificity_vs_ai_reference는 0.516, agreement_vs_ai_reference는 0.785였다(표 7). 즉 참조가 retain으로 본 문헌은 분류기가 거의 놓치지 않았으나, 참조가 deprioritize로 본 문헌의 상당수를 분류기는 retain으로 남겼다.

그 결과 겹보기 retain 비율 0.772(1,705건)는 Rogan-Gladen 보정 후 0.572(1,264건, 95% CI 1,165–1,359건)으로 낮아진다. 선별 결과를 그대로 근거 규모로 읽으면 과대추정이 발생한다는 뜻이다.

불일치 사례는 분류기 retain·참조 deprioritize 59건, 분류기 deprioritize·참조 retain 2건이며 실제 제목과 함께 산출물에 보존했다.

표 6. 라운드 간 일치

비교	Cohen kappa	라벨 일치율	상이 축 셀
라운드 1_vs_라운드 2	0.9644	98.0%	22/1,500
라운드 1_vs_라운드 3	0.9644	98.0%	22/1,500
라운드 2_vs_라운드 3	1.0000	100.0%	0/1,500

표 7. AI 참조표준 대비 지표와 95% 신뢰구간

지표	값	95% CI
sensitivity_vs_ai_reference	0.987	0.968 – 1.000
specificity_vs_ai_reference	0.516	0.466 – 0.575

agreement_vs_ai_reference	0.785	—
보정 전 겹보기 retain 비율	0.772	—
Rogan–Gladden 보정 retain 비율	0.572	0.527 – 0.615

4.4 근거 번들

정규식 게이트와 선별 라벨을 함께 적용해 1,353행이 남았고 질문별 분포는 표 4와 같다. 핵심 근거는 75건이며 한국어 번역도 같은 수만큼 작성했다. 근거 번들에는 효과 수치를 임의로 채우지 않아 효과 상태는 전부 not_observed로 남겼다.

표 4. 질문별 근거 번들 유지 행 수

질문 ID	kept
HRS1_PERIOPERATIVE	123
HRS2_KIDNEY_DISEASE	119
HRS3_PREGNANCY	372
HRS4_LIVER_DISEASE	541
HRS5_ANTICOAGULATION	198

4.5 선행 트랙과의 비교

질문 포괄성 검토 결과 v2.1의 A1, A2는 v3.0 질문이 포괄하고, B1, B2, B3는 포괄하지 못했다. 기록된 판단은 다음과 같다. “HRS5가 A1·A2를 상위 항응고제 질문으로 포괄한다. HRS2는 신장 영역이지만 만성콩팥병·투석과 신결석의 Population·Outcome이 달라 B1·B2·B3를 포괄하지 않는다.”

검색 결과 수준에서 두 트랙의 PMID 교집합은 73건, v2.1 전용은 19,546건, v3.0 전용은 2,095건이다. 두 트랙은 사실상 다른 문헌 집합을 보고 있다.

5. 고찰

5.1 주요 결과의 의미

가장 중요한 결과는 선별 통과 건수 자체가 아니라, 그 건수를 그대로 근거 규모로 읽으면 안 된다는 점을 같은 트랙 안에서 수치로 보인 것이다. 민감도는 높고 특이도는 중간 수준이라는 패턴은, 자동 선별이 놓치는 문헌을 줄

이는 쪽으로 치우쳐 있음을 뜻한다. 탐색 단계에서는 바람직한 성질이지만, 보정 없이 규모를 보고하면 근거가 실제로보다 두껍게 보인다.

라운드 간 일치가 높게 나온 것은 축 정의가 안정적으로 적용됐다는 뜻이지만, 채점자가 한 명이므로 이는 서로 다른 채점자 사이의 일치가 아니라 동일 채점자의 재검사 안정성이다. 실제로 두 번째와 세 번째 라운드는 축 셀이 하나도 다르지 않았고, 이는 독립적인 3차 판정이 아니라 2차 판정의 재현으로 보아야 한다. 정보량이 있는 값은 기준이 굳어지는 중이던 첫 라운드와의 비교뿐이다.

5.2 방법론적 기여

질문 정의부터 집필까지 사람의 연구 의사결정 없이 수행한 트랙을, 각 단계의 프롬프트 해시와 입력·출력 해시로 고정해 재현 가능하게 남겼다. 자율성을 성능 주장으로 쓰지 않고 절차 기술로 다룬 점, 그리고 그 절차가 만든 편향을 같은 트랙 안에서 보정해 보인 점이 기여다.

참조 판정을 축 단위로 나누고 종합 라벨을 코드 규칙에 맡긴 설계는, 같은 모델이 같은 기준을 두 번 적용해 일치도를 부풀리는 문제를 일부 완화한다. 다만 완전히 없애지는 못한다.

5.3 실무적 합의

자동 선별 결과를 근거 규모로 보고할 때는 참조 대조와 유병률 보정을 함께 제시해야 한다. 보정 없이 제시된 선별 통과 건수는 후속 검토 인력 산정과 근거 충분성 판단을 모두 왜곡한다.

5.4 후속 연구

다음 단계는 사람 두 명 이상이 독립적으로 같은 총화 표본을 판정해 기준 정답을 만들고, 그것과 AI 참조표준을 다시 대조하는 것이다. 그때 비로소 민감도·특이도를 임상적 의미로 해석할 수 있다. 또한 자료원을 PubMed 밖으로 넓히고, 원문 접근이 가능한 부분집합에서 초록 기반 판정과 원문 기반 판정이 얼마나 달라지는지 확인할 필요가 있다.

6. 연구의 한계

6.1 참조표준의 성격

ai_reference_standard는 사람이 만든 gold standard가 아니라 같은 에이전트가 다른 과업 정의로 수행한 내부 참조 판정이다. 따라서 본문에 보고한 sensitivity_vs_ai_reference와 specificity_vs_ai_reference는 진실 정확도가 아니며, 임상적 정확도로 인용해서는 안 된다.

6.2 독립성의 부분적 한계

분류기와 참조 판정을 같은 모델이 수행했다. 블라인드 처리와 과업 정의 분리, 라운드별 순서 무작위화로 독립성을 높였으나, 같은 모델이 공유하는 판단 성향까지 제거하지는 못한다. 그러므로 두 판정의 일치하는 서로 다른 관찰자의 합의보다 약한 증거다.

라운드 2와 3의 축 판정이 완전히 동일했다는 사실은 이 한계를 직접 보여 준다. 반복 채점이 독립적인 재판정이 아니라 앞선 판정의 재현이 될 수 있다.

6.3 사람의 연구 의사결정 부재

질문 정의, 검색식 작성, 선별, 참조 판정, 번역, 집필 전 단계에서 사람의 연구 의사결정은 0건이다. 이는 설계상의 선택이지만, 동시에 임상적 타당성을 검증할 주체가 없다는 뜻이기도 하다. 본 연구의 결과는 사람 검토를 대체하지 않는다.

6.4 단일 자료원

자료원은 PubMed 단일 자료원(pubmed_only)으로 한정했다. Embase, Scopus, Web of Science, 국내 데이터베이스, 임상시험 등록자료는 포함하지 않았다. 따라서 이 코퍼스는 가능한 모든 근거를 담은 목록이 아니다.

6.5 원문 미접근

판정과 추출은 제목과 초록 범위에서 이루어졌다. 근거 번들의 원문 위치 확보 건수는 0건이며, 접근하지 못한 원문의 내용을 근거로 해석을 넓히지 않았다. 초록에 없는 정보는 없는 것으로 두었다.

7. 결론

본 연구는 인공지능이 질문과 검색식을 정의하고 코퍼스 2,209행 전량을 직접 선별한 뒤, 총화 표본 300건에 대한 축 단위 참조 판정으로 그 선별을 교차 확인하는 완전 자율 트랙을 구축했다. 커버리지는 100%, 사람의 연구 의사결정은 0건이다.

핵심 결과는 겉보기 retain 1,705건이 보정 후 1,264건으로 낮아진다는 것이다. 자동 선별의 산출량은 그대로 근거의 양이 아니며, 참조 대조와 보정을 함께 보고할 때에만 해석 가능한 수치가 된다.

이 논문은 임상 권고도, 사람이 선별한 체계적 문헌고찰의 결론도 아니다. 의의는 자율 트랙이 무엇을 할 수 있고 어디에서 사람이 필요한지를 같은 자료 안에서 구분해 보이고, 모든 수치를 원자료와 코드에 해시로 연결해 둔 데 있다.

참고문헌

1. Page MJ, et al. The PRISMA 2020 statement: an updated guideline for reporting systematic reviews. BMJ. 2021;372:n71.
2. Rethlefsen ML, et al. PRISMA-S: an extension to the PRISMA Statement for Reporting Literature Searches in Systematic Reviews. Syst Rev. 2021;10:39.
3. Miake-Lye IM, et al. What is an evidence map? A systematic review of published evidence maps and their definitions, methods, and products. Syst Rev. 2016;5:28.
4. Rogan WJ, Gladen B. Estimating prevalence from the results of a screening test. Am J Epidemiol. 1978;107:71-76.
5. Efron B, Tibshirani RJ. An Introduction to the Bootstrap. Chapman & Hall; 1993.
6. Landis JR, Koch GG. The measurement of observer agreement for categorical data. Biometrics. 1977;33:159-174.
7. National Library of Medicine. PubMed and NCBI E-utilities documentation.
8. 연구 프로토콜 v3.0. 완전 AI 자율 근거지도 트랙. research/protocol/protocol-v3.0-full-ai.md.

부록 A. 질문별 결과표

질문 ID	hit	확보	retain	deprioritize	uncertain	번들 kept
HRS1_PERI OPERATIV E	296	296	194	92	10	123
HRS2_KID NEY_DISEA SE	138	138	126	11	1	119

HRS3_PRE GNANCY	515	515	428	85	2	372
HRS4_LIVE R_DISEASE	967	967	721	226	20	541
HRS5_ANT ICOAGULA TION	293	293	236	47	10	198

부록 B. 재현 경로와 파일 해시

항목	상대 경로	SHA-256
picos	research/searches_v3/ ai_picos/picos_definition.json	70e4749529fb2ad9db6bf7c 7c45456b9761d7958a27ee7 28371ae68015f3912f
picos_prompt	research/searches_v3/ ai_picos/prompt.txt	b8fd37a2463eab37b24e451 74ae29c06f45450d92d960 6cbdc50e82a6838e510
corpus_manifest	data/curated_v3/ corpus_manifest.json	dfce0fd19f155047b779b487 1b2605b90ee23bc50d13fbe beaf5532f592baaca
corpus	data/curated_v3/ evidence_map.csv	3142e5259bd44acec1eb270 aa66f9ff4d791e8c78013525 a666f65a8bdc5b4d3
screen_manifest	research/screening/ v30_agent/manifest.json	1d8060e90254c2476bf6fcd 3362f4e4db5a6f3afef660d3 7ea17d1ddb21a0afd

고위험 임상상황 영양보충제 안전성 근거지도 (protocol v3.0)

screen_prompt	research/screening/ v30_agent/prompts/ screening_prompt.md	d7a41a5936d13ca9f5de926 142ea2bdf4628285fab2ede c581b391cbc58ffcc
screen_output	data/curated_v3/ llm_screening_classifications. csv	5305c69437114b9f157ff6fb1 0bf1dc0308b2fca1ddacb2d0 2fc3b6848450393
reference_prompt	research/validation/ screening_ai_reference_v3/ prompts/ reference_picos_prompt.md	20a5dcddc64f2b104fc6140a 1422c5e16e035d65c58f6181 2d1067115e080b43
reference	research/synthesis/ screener_vs_ai_reference_v3. json	e55e21e74842867516f3099 6d9d0df93067ef3b20e4371 ea38fc2f51bb6ad89e
review_manifest	research/ systematic_review_v30/ manifest.json	3d0e9fa66b11f9e95631d48f 7fe35bb48f5b7dd68f2c2160 353012d098a0c15f
core_manifest	research/ systematic_review_v30/ core_manifest.json	d6a6190301939ce45a838e d4ffec5f1b4b661223962af8 298fcbef80534f64a6
track_comparison	research/synthesis/ picos_track_comparison.json	84b40e1c3f7c770dab812e4 82176b593c707b3007f98a8 a9648c328775473480

표의 수치는 문서에 고정 입력하지 않고 각 manifest에서 읽어 생성하였다. 해시가 달라지면 검증 절차를 다시 수행해야 한다. 위 표의 SHA-256은 원시 바이트 기준이며, 선별 manifest는 개행 차이를 흡수하기 위해 LF 정규화 후 해싱한 값을 따로 기록한다(hash_method: sha256_over_lf_normalized_bytes).